UTN FRM · INGENIERÍA EN SISTEMAS DE INFORMACIÓN · CIENCIA DE DATOS 2026

# Guión de la defensa

*Entrega 2 · Análisis exploratorio · Veinte minutos, cuatro voces, una sola pregunta de fondo: ¿sabemos qué tiene adentro el dataset, y podemos defender con un número cada decisión que tomamos sobre él?*

**Grupo 5K09-02**

Proyecto FF-15 — predicción de la duración de una partida de League of Legends

Exposición: miércoles 23 de septiembre · 20 minutos con el docente, en privado

Se muestra desde: **Google Colab**, con el notebook `notebooks/entrega-2/eda_entrega2.ipynb` (versión del 22/9)

---

Ezequiel Aguilar · Rodrigo «Toto» Viluron

Anthony «Cocha» Cochachin · Facundo Aracena

---

SECCIÓN 1

# Cómo usar este guión

La consigna lo dice dos veces: **la evaluación es individual** y «que hable uno solo es el error más caro, porque las preguntas van dirigidas y la nota es individual». Por eso los primeros siete minutos están repartidos en cuatro turnos, y cada una de las ocho fichas tiene una persona que la *arranca* si el docente la elige.

El texto sobre fondo amarillo es **lo que se dice**, escrito para sonar hablado. No se lee el día de la entrega: se ensaya hasta poder decirlo mirando la pantalla. Lo que está debajo son los datos que lo sostienen, por si el docente frena en el medio. Todos los números de este guión salen de las salidas guardadas del notebook o se recalcularon sobre el mismo CSV; ninguno es de memoria.

| REGLA | POR QUÉ |
|---|---|
| **El reparto es para arrancar, no para saber** | La consigna: «la pregunta sobre una hipótesis puede caerle a quien hizo la limpieza». Las ocho fichas, el perfil y la tabla de candidatas los tienen que poder recorrer los cuatro. El dueño de una ficha es quien empieza a hablar si cae; nada más. |
| **Se contesta con un número, nunca con el gráfico** | «Se ve que hay diferencia» es una de las tres formas de perder los 20 minutos que lista la consigna. Cada respuesta arranca con el número y su zona; el gráfico viene después, a explicarlo. |
| **Nadie interrumpe el turno de otro** | Si a alguien se le escapa un dato, el que sigue lo retoma. Corregir a un compañero delante del docente come tiempo y hace que el grupo se vea desarmado. |
| **Cada turno se cierra con el pase** | Una frase que nombra al que sigue. Evita el silencio entre turnos. |
| **Si no sabés, decilo y devolvé algo** | «Eso lo trabajó Toto, pero lo que sí te puedo decir es…». Nunca inventar un número: se descubre en la repregunta. Y la consigna lo premia: «si algo no te dio, vení igual y decilo». |

> LA FRASE QUE RESUME LA ENTREGA
>
> «**Las condiciones iniciales de una partida no dicen cuánto va a durar, pero sí se dicen mucho entre ellas.** La mejor columna explica el 2,6 % de la varianza de la duración; en cambio, cuatro pares de columnas se duplican con fuerza medida. Por eso llegamos a la Entrega 3 con 82 columnas afuera, cada una con su razón, y con un rival claro: predecir 1.748 segundos siempre.»

## Las tres formas de perder los 20 minutos (de la consigna)

- **El EDA de checklist.** «Veinte gráficos, ninguna conclusión.» → Cada turno de este guión termina en una decisión.
- **Contestar con el gráfico.** «Un gráfico no se compara contra nada; el número sí.» → Cada ficha dice su número y su zona antes de mostrar el gráfico.
- **Que hable uno solo.** → Cuatro turnos y dos fichas por persona.

SECCIÓN 2

# Antes de entrar al aula

La consigna: «Llegá con esto ya hecho. Los 20 minutos son para mostrar y explicar, no para correr celdas ni para esperar que termine un gráfico». Y: el notebook «abierto antes de entrar. Si hay que correrlo delante nuestro, son minutos que no recuperás».

### LA NOCHE ANTERIOR (MARTES 22)

| QUÉ | QUIÉN |
|---|---|
| ☐ Subir a Google Colab **la versión del 22/9** del notebook: la que tiene las fichas reordenadas (H1 tanques, H2 maestría, H3 t1/t2, H4 elo…). Una copia subida antes de esa fecha tiene **la numeración vieja** y no coincide con este guión. | Quien lleva la notebook |
| ☐ Abrirlo en Colab y comprobar que se ven las salidas guardadas: tablas, los doce gráficos y la tabla de columnas candidatas con estilo. | Quien lleva la notebook |
| ☐ Simulacro completo: los turnos cronometrados, dos fichas elegidas al azar por otro integrante, y después preguntas del banco de la sección 7. | Los cuatro |
| ☐ Cada uno lee **las ocho fichas**, no sólo las suyas. | Los cuatro |

### QUINCE MINUTOS ANTES

| QUÉ | DETALLE |
|---|---|
| ☐ Colab abierto en el notebook, parado en el título, con el panel **Índice** (tabla de contenidos) de la barra izquierda desplegado. | Así se salta a cualquier ficha con un clic. |
| ☐ **No ejecutar ninguna celda.** Las salidas ya están guardadas. | Si alguien re-ejecuta, la primera celda de código busca el CSV en una carpeta `datos/`; si no se subió a la sesión de Colab, falla. |
| ☐ Zoom del navegador en 110–125 % y notificaciones silenciadas. | Se proyecta o se mira de cerca. |

☐ Este guión abierto en otro dispositivo, no en la pantalla que se muestra.

> **CÓMO SE REFERENCIA EL NOTEBOOK EN ESTE GUIÓN**
>
> Colab no numera las celdas de forma estable, así que el guión remite a dos cosas que sí se encuentran siempre: **el título de la sección**, tal como aparece en el Índice (por ejemplo «H2 · La maestría binarizada pierde el orden de magnitud»), y **la primera línea de la celda de código**, que en todo el notebook es un comentario que dice qué se pregunta (por ejemplo `# Las tres formas de agregar la misma columna…`).

SECCIÓN 3

# El reparto de un vistazo

| Facundo 0:00–2:00 | Ezequiel 2:00–4:30 | Toto 4:30–7:00 | Cocha 7:00 | Dos fichas 7:45–13:00 | Preguntas dirigidas 13:00–18:00 | Devolución 18–20 |
|---|---|---|---|---|---|---|

| QUIÉN | RELOJ | QUÉ EXPONE | MOMENTO DE LA CONSIGNA |
|---|---|---|---|
| **Facundo Aracena** | 0:00 – 2:00 | Qué cambió desde la Entrega 1, qué es una fila, la clave, el tamaño y los tipos. | «Qué cambió» (0–2) |
| **Ezequiel Aguilar** | 2:00 – 4:30 | La columna objetivo: su distribución, el corte de los 300 s, el escalón de los 900 s y las bandas de minutos. | «El perfil» (2–7) |
| **Rodrigo «Toto» Viluron** | 4:30 – 7:00 | La calidad: duplicados, constantes, por qué no hay nulos, los ceros que son faltantes y la asimetría. | |
| **Anthony «Cocha» Cochachin** | 7:00 – 7:45 | El puente: el método en tres frases y el menú de las ocho fichas. | «Dos hipótesis» (7–13) |
| **El dueño de cada ficha elegida** | 7:45 – 13:00 | Las dos fichas que elija el docente, enteras, desde la afirmación hasta la decisión. Unos 2:30 cada una. | |

## Las ocho fichas, en el orden en que se ofrecen, y quién las arranca

| FICHA | GRUPO | PREGUNTA | NÚMERO · ZONA | LA ARRANCA |
|---|---|---|---|---|
| **H1** · más tanques, partida más larga | principal | responder | Pearson −0,008 · **rojo** · refutada | Ezequiel |
| **H2** · la maestría binarizada pierde información | principal | predecir | 0,471 → 0,769 · **amarillo** → **verde** | Toto |
| **H3** · la partición t1/t2 duplica | secundaria | predecir | \|t1−t2\| 0,0126 · **rojo** (confirma) | Cocha |
| **H4** · a más elo, partidas más cortas | secundaria | responder | Pearson −0,161 · **rojo** · refutada | Facundo |
| **H5** · rango largo, armadura baja | restante | responder | Pearson −0,672 · **verde** | Ezequiel |
| **H6** · el elo y el winrate son lo mismo | restante | predecir | Pearson 0,711 · **verde** | Facundo |
| **H7** · `avg_defense` es `num_tanks` | restante | predecir | $\eta^2$ 0,319 · **verde** | Cocha |
| **H8** · `count_flash` no aporta | restante | predecir | modal 0,838 y −0,014 · **rojo** (confirma) | Toto |

> **POR QUÉ ESTE REPARTO**
>
> Cada uno tiene una de las cuatro primeras y una de las cuatro restantes, y las dos fichas de cada persona tocan el mismo tema que su turno o entre sí: Ezequiel, composición y diseño del juego (H1, H5); Toto, la maestría y la columna casi constante, que es calidad (H2, H8); Cocha, el bloque de agregados de equipo (H3, H7); Facundo, el elo (H4, H6). Así, si el docente elige dos fichas del mismo dueño, la segunda la arranca otro: **la regla es que nadie arranca dos seguidas**. El que no arrancó ninguna toma la segunda.

**Si el docente deja elegir**, se ofrecen las dos principales, H1 y H2: juntas cubren lo que la consigna quiere ver —una hipótesis que salió mal y el método entero con un movimiento—. Y si pregunta por qué hay ocho, está contestado en la sección 7.

SECCIÓN 4

# Los primeros siete minutos, turno por turno

## 1 · Facundo Aracena — 0:00 → 2:00

Qué cambió · qué es una fila · tamaño, clave y tipos

**En Colab:** el título del notebook, con la pregunta del proyecto. Después, en el Índice, **Sección 1 · Inspección inicial del dataset** → «Dimensiones, y qué es una fila» (celda `# Observaciones y variables`) y «Tipos de datos» (`# Cuántas columnas hay de cada tipo`).

LO QUE DECÍS

Buenas, somos el grupo 5K09-02. Primero, qué cambió desde la Entrega 1: **nada**. No nos marcaron correcciones, y ni la pregunta del proyecto ni el esquema cambiaron. El dataset que analizamos es el mismo que presentamos el 9 de septiembre.

La pregunta sigue siendo si se puede predecir cuánto dura una partida de *League of Legends* con lo que se sabe antes de que arranque. **Una fila es una partida clasificatoria de cola 420, solo/dúo, de la Season 16.** Son **19.145 partidas por 137 columnas**, y la clave es `match_id`, que trae adentro el prefijo del servidor.

Las 137 columnas no se leen de a una: son tres bloques. Tres de identidad, objetivo y calidad; cien que son los diez jugadores aplanados —diez features por cinco posiciones por dos equipos—; y treinta y cuatro agregados de equipo, diecisiete por equipo.

De tipos: 106 enteras, 20 decimales y 11 de texto. Ninguna numérica quedó como texto: las once de texto son `match_id` y los diez nombres de campeón. Lo que sí hay que marcar es lo contrario: `champ_id`, los hechizos y las runas son **códigos guardados como enteros**, etiquetas y no cantidades.

Ezequiel les muestra la columna objetivo.

**Los datos de este bloque, por si frenan acá:**

- Seis servidores, entre 2.950 (EUW1) y 3.430 (KR) partidas cada uno (celda `# Cuántas partidas trajo cada servidor`).
- `t1` es el `teamId` 100 y `t2` el 200: un rótulo arbitrario de Riot. Eso es H3.
- La plataforma no es una columna del esquema: se deriva del prefijo de `match_id` en la celda `# Todas las derivadas del análisis…`.
- **Tidy, si lo preguntan:** la fila es una partida y eso está bien, pero «el elo del jugador» no es una columna, son diez. Es una concesión deliberada: diez filas por partida romperían la clave y la pregunta es sobre partidas. Esta explicación no está en el notebook; se dice de palabra.

→ Pase: «Ezequiel les muestra la columna objetivo.»

## 2 · Ezequiel Aguilar `2:00 → 4:30`

La columna objetivo · el número más importante de la entrega

**En Colab: Sección 2 · Análisis univariado** → «La columna objetivo…» (celdas `# El objetivo: centro, dispersión y colas` y el histograma). Después «El escalón de los quince minutos» (el histograma ampliado, con la línea en 900 s) y «La distribución del objetivo, cuando el objetivo es continuo» (la tabla de bandas).

LO QUE DECÍS

El objetivo es `game_duration_s`, la duración en segundos: continua, así que el problema de la Entrega 3 es de regresión. Media **1.748** segundos, mediana **1.751**, desvío 424.

Lo inesperado es la forma: **asimetría −0,039 y curtosis 0,579**. Es prácticamente simétrica, y eso contradice lo que suele pasar con una duración, que casi siempre tiene cola derecha y pide logaritmo. Ésta no: **el objetivo no necesita transformarse**.

Tiene dos cosas que hay que declarar. La pared de la izquierda **es nuestra**: el pipeline descarta las partidas de menos de 300 segundos porque son *remakes*. Y tiene un escalón: **del minuto 14 al 15 terminan 27 partidas; del 15 al 16, 714**. A los quince minutos se habilita la rendición. No es un error: es el fenómeno, y además es un control de calidad, porque cae justo donde el reglamento dice. Son el 3,7 % del dataset en un punto, y un modelo que prediga un número suave no lo va a reproducir.

La consigna mide la distribución con `value_counts`, pero con 2.180 valores distintos eso no dice nada, así que agrupamos en bandas de minutos. **La banda más poblada, de 25 a 30 minutos, tiene el 29,9 %**: no hay una clase que se coma todo. El reverso: un modelo que prediga siempre la media ya va a parecer decente, así que ése es el rival de la Entrega 3.

Toto sigue con la calidad del dato.

**Los datos de este bloque:**

- Mínimo 301 s, máximo 3.963 s. Percentil 1: 724,9; percentil 99: 2.778,6.
- De los diez valores de duración más repetidos, seis caen entre 911 y 918 segundos.
- Bandas: <20 min 10,2 % · 20–25 15,1 % · 25–30 29,9 % · 30–35 26,2 % · 35–40 12,8 % · 40+ 5,8 %.
- Extremos (Sección 4): 137 partidas de menos de 10 minutos y 289 de más de 45. No se sacan: son el fenómeno. El único recorte legítimo es el de los remakes.

→ Pase: «Toto sigue con la calidad del dato.»

## 3 · Rodrigo «Toto» Viluron — 4:30 → 7:00

Calidad · duplicados, constantes, nulos y los ceros que mienten

**En Colab: Sección 4 · Análisis de calidad de datos** → «La clave…» (`# La misma pregunta con tres claves distintas`), «Columnas sin información…», «Valores faltantes: cero, y ése es justamente el tema» (`# La masa de valores imputados…`) y «Dos ceros, dos significados…».

> LO QUE DECÍS
>
> Duplicados: **cero**, y lo medimos con tres claves: por `match_id`, por fila completa y por los diez campeones. Que los diez campeones no se repitan ni una vez en 19.145 partidas dice que cada composición es única. El cero de la clave no es suerte: el DAG deduplica y falla la corrida si la clave repite.
>
> Constantes: **ninguna**, porque `count_smite` ya la sacamos antes de la Entrega 1. Casi constantes sí: `roles_inferidos` vale 0 en el **99,91 %** de las filas —17 partidas— y los `count_flash` tienen su valor modal en el 84 %.
>
> Nulos: **cero en las 137 columnas, y ésa es una decisión, no una propiedad**. Un jugador sin ranked recibe elo 1500 y winrate 0,50: habilidad desconocida, promedio. Es una tercera categoría, además de los faltantes reales y los estructurales. Se cuenta buscando el valor imputado: el elo en 1500 es el **0,55 %** de las celdas de jugador. Pero 1500 también le pasa a un Silver III con 50 puntos, así que exigimos elo 1500 *y* winrate 0,50 a la vez: eso descarta 111 falsos positivos y deja 944 celdas en 615 partidas.
>
> Y un caso donde el cero miente: `rune_sub` tiene 27 ceros que son faltantes disfrazados. **Cinco celdas** llevan la asimetría de `t1_jng_rune_sub` de −24,22 a −0,40. Un criterio automático sobre la asimetría habría mandado a transformarla, y transformar no arregla nada. El cero de la maestría, en cambio, es real: el jugador nunca jugó ese campeón.
>
> Cocha les cuenta cómo resolvimos las hipótesis.

**Los datos de este bloque:**

- Winrate en 0,50: 3,57 % de las celdas, casi todos jugadores reales con historial parejo.
- Por partida: 18.530 sin imputados, 512 con uno; **24 con nueve y 2 con diez**. Sospechamos una tanda de consultas fallida, no nueve jugadores sin clasificar. No se verificó: hace falta el bronce de la corrida grande. Es un pendiente declarado.
- Asimetría por familia: casi todas entre −0,5 y 0,6. Cola larga real sólo en la maestría (mediana de la familia 4,67; mediana 111.880 puntos, máximo 13.841.137). `champ_id` da 1,71 pero es un código: su asimetría no significa nada.
- `champ_id` y `champ_name`: 173 y 173, uno a uno, cero `Unknown`.

→ Pase: «Cocha les cuenta cómo resolvimos las hipótesis.»

## 4 · Anthony «Cocha» Cochachin

7:00 → 7:45

El puente · el método y el menú de fichas

**En Colab: Sección 7** → «El semáforo» (la tabla de cortes), y enseguida **Sección 9** → «El resumen de las ocho fichas».

LO QUE DECÍS

Cada hipótesis se escribió antes de medir, y la forma de la afirmación fija la medida: comparación, asociación o composición. El número cae en una zona del semáforo con los cortes de la cátedra: verde y rojo cierran la ficha; amarillo habilita un movimiento, con tope de dos.

Hicimos **ocho fichas, ordenadas por importancia**. Las cuatro primeras cumplen solas la consigna: hay de las dos preguntas y dos salen refutadas. Y el resultado de fondo es que **las cuatro que miden contra la duración dan rojo, y las cuatro que miden una columna contra otra dan verde**. ¿Cuáles querés que recorramos?

→ Si deja elegir: «Arrancamos por la H1, la que nos salió mal. Ezequiel.»

SECCIÓN 5

## Las ocho fichas, en orden de importancia

Cada ficha tiene su texto de unos dos minutos y medio, que recorre las seis casillas: afirmación, qué esperábamos ver, por qué esa medida, resultado con su zona, movimiento si lo hubo, y qué hacemos con eso. En Colab, cada una está en **Sección 8**, bajo su grupo.

### Principal · H1 · Más tanques, partida más larga

`arranca Ezequiel`

Principal · pregunta de dominio («qué queremos responder») · asociación · **rojo** · refutada

**En Colab:** Sección 8 → Las dos fichas principales → **«H1 · Las composiciones con más tanques alargan la partida»**. Celdas `# Los tanques de los dos equipos juntos contra la duración` y `# La duración mediana por cantidad de tanques…` (gráfico de dos paneles y la tabla).

LO QUE DECÍS

**Afirmación:** cuantos más tanques hay en la partida, más dura. El tanque no mata rápido y es difícil de matar, así que las peleas se estiran y cerrar cuesta más.

**Qué esperábamos:** una relación positiva y clara. De las tres de dominio, era la que más convencidos nos tenía: es lo que diría cualquiera que juegue.

**Medida:** dos numéricas —tanques de la partida, de 0 a 10, contra segundos—, así que es asociación: Pearson y Spearman.

**Resultado: Pearson −0,008, rojo.** Spearman −0,007. Es el número más cercano a cero de las ocho fichas, y encima con el signo al revés. **Refutada.**

El gráfico sirve para ver una trampa. La línea de medianas parece bajar al final, pero el panel de al lado muestra que con 7 y 8 tanques hay **3 partidas y 1**. Donde hay datos, de 0 a 5 tanques, que es el 99,7 % de las filas, las medianas van de 1.737 a 1.757 segundos: veinte segundos de diferencia sobre un desvío de 424. Mirando sólo la línea, habríamos creído que había una caída.

**Qué hacemos con eso:** la conclusión sobre el juego es que la cantidad de tanques no dice nada de cuánto va a durar la partida. Pero `num_tanks` no sale por esto: una columna no se descarta porque falle una hipótesis sobre ella. Entra a la Entrega 3 como suma de los dos equipos, con el resto de la composición.

**Si frena acá:**

- Medianas por cantidad de tanques: 0 → 1.752 · 1 → 1.751 · 2 → 1.757 · 3 → 1.748 · 4 → 1.737 · 5 → 1.738 segundos. Con 6 son 59 partidas.
- ¿Por qué no hubo movimiento? Rojo cierra la ficha. Insistir sobre un rojo, partiendo la población hasta encontrar un subgrupo, es cazar resultados.
- La misma variable contra la duración con $\eta^2$ (en H7) da 0,001: también rojo.

## Principal · H2 · La maestría binarizada pierde el orden de magnitud

`arranca Toto`

Principal · decide sobre columnas («qué queremos predecir») · asociación · **amarillo** → **verde** · confirmada

**En Colab:** Sección 8 → Las dos fichas principales → **«H2 · La maestría binarizada pierde el orden de magnitud»**. Celdas `# Qué tan exigente es el umbral que elegimos`, `# El conteo de mains contra la maestría agregada…`, el gráfico `# Los dos paneles que eligen el movimiento…` y `# Las tres formas de agregar la misma columna…`.

LO QUE DECÍS

**Afirmación:** `is_main` es la maestría mayor o igual a 50.000 puntos, un umbral que elegimos nosotros, y `mains_count` los cuenta por equipo. Binarizar tira información; la pregunta es cuánta. Si la bandera conserva casi todo, sobra la continua; si no, sobra la bandera.

**Qué esperábamos:** verde de entrada, sin movimientos. El umbral nos parecía razonable.

**Medida:** asociación, Pearson y Spearman, y acá la casilla que más importa es la brecha entre los dos, porque la maestría tiene una cola larguísima.

**Resultado parcial: Pearson 0,471, amarillo; brecha 0,078, también amarillo.** Es la única ficha de las ocho que cae en amarillo. Y el primer número explica por qué: el umbral de 50.000 marca como «main» al **67,9 %** de los jugadores, cuando la mediana es 111.880. No separa especialistas: se prende para dos de cada tres.

El movimiento lo elige el gráfico: la curva sube pero no es recta, y la maestría es una cola de hasta trece millones de puntos. Un solo *one-trick* mueve el promedio de los diez. Brecha grande más cola larga es el caso de **cambiar la escala**. Pero importa dónde: la bandera se arma jugador por jugador, así que el logaritmo también va jugador por jugador, antes de promediar.

**Resultado tras el movimiento: 0,769, verde**, Spearman 0,829. Y el mismo logaritmo aplicado al promedio ya calculado da 0,582: sigue amarillo. Aplicado en el lugar equivocado, el movimiento no alcanzaba.

**Qué hacemos con eso:** confirmada, y salen **doce columnas**: los diez `is_main` y los dos `mains_count`. Queda la maestría, en logaritmo por jugador antes de promediar. Si alguna vez hace falta una bandera, el umbral lo elige el dato, por ejemplo el percentil 90, que es 1.011.698 puntos, y no el grupo a ojo.

**Si frena acá:**

- Asimetría de la maestría por jugador: 4,80. Un movimiento, de los dos que permite el tope.
- Salvedad escrita en la ficha: el promedio del logaritmo tiene asimetría −3,88, por las 22 partidas donde nadie supera el umbral y arrastran ceros reales. No mueven el Spearman.
- Reparo de fuga: la maestría se lee después de la partida y ya suma los puntos de esa misma partida. Está declarado en la Sección 9.

## Secundaria · H3 · La partición t1/t2 duplica la información

arranca Cocha

Secundaria · decide sobre columnas · asociación · **rojo**, que acá confirma · la que más cambia la Entrega 3

**En Colab:** Sección 8 → Las dos fichas secundarias → **«H3 · La partición t1/t2 duplica la información»**. Celdas `# Cada agregado, medido cuatro veces contra el objetivo`, `# Los dos números que deciden` y el gráfico `# El mismo agregado, medido de las cuatro formas`.

LO QUE DECÍS

**Afirmación:** `t1` y `t2` son los `teamId` 100 y 200, que Riot asigna sin criterio: no hay equipo local ni favorito. Entonces cada agregado se tiene que relacionar igual con la duración en los dos equipos, y las 34 columnas del bloque de equipo son 17 repetidas.

**Qué esperábamos:** la misma correlación para las dos mitades, y además que la suma de los dos equipos correlacione mejor que cada mitad.

**Medida:** cada agregado, medido cuatro veces contra el objetivo: la mitad de t1, la de t2, la suma y la diferencia absoluta. Decide la diferencia entre las dos primeras correlaciones. Acá **el rojo confirma**: si la diferencia es roja, las mitades son indistinguibles, que es lo que afirmamos.

**Resultado: la diferencia es 0,0126 en promedio y 0,028 como máximo, rojo**, siete veces por debajo del corte. Y la suma es la mejor de las cuatro formas en **11 de los 17** agregados: magos pasa de 0,044 y 0,053 por separado a 0,069 sumado.

El porqué está en la celda del medio: las composiciones de los dos equipos son independientes entre sí, y sumar dos medidas independientes del mismo fenómeno cancela ruido.

**Qué hacemos con eso:** confirmada. Los agregados entran como suma de los dos equipos. Contando las otras fichas que sacan agregados, de 34 columnas quedan 24, y se colapsan en **12 sumas**. «Cuántos magos hay en la partida» es una variable del juego; «cuántos tiene el equipo al que Riot le puso el 100», no.

**Si frena acá:**

- Los cinco agregados que salen por otras fichas: `mains_count` (H2), `avg_defense` y `avg_magic` (H7), `total_base_armor` (H5), `count_flash` (H8). 17 − 5 = 12.
- La mayor correlación entre `t1_X` y `t2_X` es `mains_count`, 0,176. De `num_marksmen` se conserva también la diferencia absoluta, que fue su mejor forma.
- El mismo argumento vale para las cien columnas de jugador: queda como recomendación agregarlas por partida.

## Secundaria · H4 · A más elo, las partidas son más cortas

`arranca Facundo`

Secundaria · pregunta de dominio · asociación · **rojo** · refutada · lleva al hallazgo de fondo

**En Colab:** Sección 8 → Las dos fichas secundarias → **«H4 · A más elo, las partidas son más cortas»**. Celda `# El elo medio de los 10 jugadores contra la duración` y el gráfico `# La nube completa, y la duración mediana por decil de elo`. Para cerrar: Sección 9 → «El hallazgo que atraviesa las ocho».

LO QUE DECÍS

**Afirmación:** cuanto mejores son los diez jugadores, más corta es la partida: convierten una ventaja en objetivos más rápido y cierran antes.

**Qué esperábamos:** una nube que baja. No fuerte, pero sí la relación más fuerte del dataset, porque el elo es lo único que mide directamente cuán bien se juega.

**Medida:** asociación entre el elo medio de la partida y la duración, Pearson y Spearman, con la brecha como control de curvatura.

**Resultado: Pearson −0,161, Spearman −0,155, rojo. Brecha 0,006, rojo:** no hay curva escondida. El signo es el esperado y la magnitud no alcanza. **Refutada, y rojo cierra.**

En el gráfico, la nube es una banda horizontal. Promediando por decil sí baja, pero no monótonamente —sube hasta el cuarto decil, 1.848 segundos— y de punta a punta son **202 segundos** sobre todo el rango de elo: una tendencia real, chica y sucia.

**Qué hacemos con eso:** se descarta la afirmación, no la columna. El elo sigue siendo la columna más asociada al objetivo de las 137, así que entra a la Entrega 3 agregado por partida, como candidata débil. Y es el número del hallazgo de fondo: **la mejor columna del dataset explica el 2,6 % de la varianza de la duración**. Con estas features, medidas de a una, la respuesta a la pregunta del proyecto por ahora es no; si hay señal, está en combinaciones, y eso lo decide el modelo.

**Si frena acá:**

- Medianas del primer y último decil de elo: 1.803 y 1.601 segundos.
- **Si pregunta por el servidor** (respuesta oral: ese control se quitó del notebook al simplificarlo, y se recalculó el 22/9 sobre el mismo CSV). Dentro de cada servidor, partida a partida, la correlación va de −0,014 (NA1) a −0,254 (KR): controlar el servidor no rescata nada. Y comparando los **seis promedios** de servidor da −0,682, verde: es la trampa de agregación. Seis puntos no son partidas; para predecir una partida manda el −0,161.
- El winrate, la segunda del ranking, da −0,120. Ver H6.

## Restante · H5 · Los campeones de rango largo son de armadura baja `arranca Ezequiel`

Pregunta de dominio · asociación · **verde** · confirmada · sale `total_base_armor`

**En Colab:** Sección 8 → Las cuatro fichas restantes → **«H5 · Los campeones de rango largo…»**. Celdas `# El alcance medio de los 10 campeones contra la armadura base…`, el gráfico por octil y `# Las tres columnas de estadísticas base…`.

LO QUE DECÍS

**Afirmación:** alcance de ataque y armadura base son la misma decisión de diseño: el que pega de lejos lo paga siendo frágil. Si es así, `avg_attackrange` y `total_base_armor` cuentan lo mismo con el signo cambiado, y una sobra. La hipótesis **salió de la matriz de correlación de la Sección 3**, donde apareció un −0,654 sin buscarlo; lo declaramos en la ficha.

**Qué esperábamos:** una nube fuerte que baja, sin curvatura.

**Medida:** asociación a nivel de partida, Pearson y Spearman con brecha.

**Resultado: Pearson −0,672, verde;** Spearman −0,653, brecha 0,019, recta. La armadura mediana cae de 312 a 280 del primer al último octil de alcance, en los ocho escalones: más de dos desvíos.

**Qué hacemos con eso:** sale `total_base_armor`, dos columnas. La armadura es el centro de dos redundancias a la vez —0,672 con el alcance y 0,529 con la vida base— así que sacarla resuelve las dos. Contra la duración las tres son rojas (0,054; −0,066; −0,003), así que eso no sirve para desempatar, y no lo usamos.

## Restante · H6 · El elo y el winrate son la misma columna

`arranca Facundo`

Decide sobre columnas · asociación · **verde** · confirmada · salen los diez `player_winrate`

**En Colab:** Sección 8 → **«H6 · El elo y el winrate son la misma columna»**. Celda `# El elo medio de la partida contra el winrate medio…` y el gráfico por decil.

LO QUE DECÍS

**Afirmación:** elo y winrate salen de la misma respuesta de la API y miden lo mismo, porque la única forma de subir es ganar más de lo que se pierde.

**Qué esperábamos:** fuerte pero no perfecta: el elo es acumulado y el winrate es la tasa del momento. Verde, no 0,95.

**Medida:** asociación entre los dos promedios por partida, con brecha.

**Resultado: Pearson 0,711, Spearman 0,748, verde;** brecha 0,037, recta. El winrate mediano sube de 0,478 a 0,537 del primer al décimo decil de elo, sin una inversión: seis puntos de winrate, porque el winrate vive apretado alrededor de 0,50 por construcción.

**Qué hacemos con eso:** salen los diez `player_winrate` y quedan los `player_elo`, por tres razones: la redundancia es verde; el elo conserva más de la poca señal que hay, −0,161 contra −0,120; y el winrate tiene el peor reparo de fuga, porque ya cuenta el resultado de esta misma partida.

## Restante · H7 · avg_defense es num_tanks escrito de otra forma

arranca Cocha

Decide sobre columnas · **comparación** · verde ($\eta^2$) · confirmada · salen `avg_defense` y `avg_magic`

**En Colab:** Sección 8 → **«H7 · avg_defense es num_tanks…»**. Celdas `# Lo que la cantidad de tanques explica de la defensa media, con las dos medidas`, `# El control: la misma categoría de once niveles…` y el boxplot.

LO QUE DECÍS

**Afirmación:** el bloque de equipo dice lo mismo dos veces: cuántos campeones tienen el tag `Tank`, y el promedio de la estadística `defense` de esos cinco. Si describen al mismo campeón, saber cuántos tanques hay explica buena parte de la defensa media, y una columna sobra. También salió de la matriz de correlación, y lo declaramos.

**Qué esperábamos:** verde; casi una definición.

**Medida:** la afirmación es una **comparación entre grupos** —la defensa difiere según cuántos tanques hay— y esa forma trae **$\eta^2$**. El conteo de 0 a 10 se lee como grupo.

**Resultado: $\eta^2$ 0,319, verde**: los tanques explican el 31,9 % de la variación de la defensa media. Pearson da 0,565, amarillo, y los dos números están a la vista: la medida se fijó por la forma de la afirmación, no por cuál convenía. $\eta^2$ no exige que la relación sea recta; Pearson sí.

El control contra la objeción de que $\eta^2$ sube con muchos grupos: la misma categoría de once niveles contra la duración da 0,001, y contra el alcance 0,129. Si fuera azar, serían parecidas. Y magia contra magos da 0,310: mismo mecanismo.

**Qué hacemos con eso:** salen `avg_defense` y `avg_magic`, cuatro columnas; quedan `num_tanks` y `num_mages`, porque entre dos que miden lo mismo se queda la que se explica en una frase.

## Restante · H8 · count_flash no aporta información

`arranca Toto`

Decide sobre columnas · dos medidas · **rojo**, que acá confirma · salen los dos `count_flash`

**En Colab:** Sección 8 → **«H8 · count_flash no aporta…»**. Celdas `# Cuán concentrado está el reparto…`, `# ¿Y aporta algo, aunque varíe poco?` y `# Los otros dos contadores de hechizos…`.

LO QUE DECÍS

**Afirmación:** `count_flash` es otra `count_smite`: casi todos llevan Destello, así que la columna casi no varía y no puede distinguir partidas.

**Qué esperábamos:** un reparto muy concentrado y una asociación con la duración indistinguible de cero.

**Medidas:** son dos partes, así que dos números: el peso del valor más frecuente, y la asociación con el objetivo, porque una columna puede variar poco y aun así informar.

**Resultado:** el **83,8 %** de los equipos lleva los cinco Destellos y el 70,1 % de las partidas tiene diez de diez. Contra la duración, **Pearson −0,014, rojo**, $\eta^2$ 0,0002. Confirmada.

Y un control que corrige el argumento: teletransporte e ignición varían mucho más —valor modal en 33 % y 30 %— y también dan rojo, 0,017 y 0,044. O sea que los hechizos no explican la duración, y la varianza baja de Destello es un motivo aparte para sacarla.

**Qué hacemos con eso:** salen los dos `count_flash`, con el mismo criterio que `count_smite` pero con dos números. Teletransporte e ignición se quedan: tienen varianza real, y correlacionan −0,543 entre sí porque compiten por el mismo lugar.

SECCIÓN 6

# Lo que se verifica con un número, y lo que la consigna dice que se pregunta

## Los siete números de la consigna

| QUÉ | QUÉ DA | QUÉ HAY QUE SABER DECIR | DÓNDE EN COLAB |
|---|---|---|---|
| Tamaño | **19.145 × 137** | Una fila es una partida clasificatoria de cola 420, Season 16. | Sección 1 · «Dimensiones…» |
| Tipos | 106 int64 · 20 float64 · 11 object | Ninguna numérica como texto: los 11 son `match_id` y los 10 `champ_name`. Sí hay códigos guardados como enteros. | Sección 1 · «Tipos de datos» |
| Nulos | **0** en las 137 | Los faltantes se imputaron aguas arriba: elo 1500 y winrate 0,50. Elo 1500 en el 0,55 % de las celdas de jugador. | Sección 4 · «Valores faltantes…» |
| Constantes | **Ninguna** | `count_smite` ya salió antes de la Entrega 1. Casi constante: `roles_inferidos`, 99,91 %. | Sección 4 · «Columnas sin información…» |
| Duplicados de la clave | **0** | También 0 por fila completa y por los diez campeones. | Sección 4 · «La clave…» |
| Distribución del objetivo | banda máxima **29,9 %** | Continuo: 2.180 valores distintos, así que va en bandas de minutos. Sin desbalance. | Sección 2 · «La distribución del objetivo…» |
| Asimetría | objetivo −0,039 | Cola larga real sólo en la maestría. Los −24 de `rune_sub` son cinco ceros. | Sección 2 · «Las medidas de forma…» |

## Las cinco preguntas que la consigna anticipa

### 1 · Cuál es la variable objetivo y cómo está distribuida

EZEQUIEL

**`game_duration_s`, continua, en segundos. Media 1.748, mediana 1.751, asimetría −0,039: simétrica, sin desbalance —la banda más poblada es el 29,9 %— y no necesita transformarse.**

Truncada a izquierda en 300 s por decisión nuestra (remakes), y con un escalón de 714 partidas en el minuto 15, cuando se habilita la rendición.

### 2 · Por qué hay nulos donde hay nulos

TOTO

**No hay nulos, y ésa es la respuesta: los faltantes se convirtieron en valores por defecto en el pipeline. Es una tercera categoría, además de los faltantes reales y los estructurales.**

Sin ranked: elo 1500 y winrate 0,50 (0,55 % de las celdas por el elo; con los dos a la vez, 944 celdas en 615 partidas). Un cero que sí es faltante: los 27 ceros de `rune_sub`. Un cero que es real: los 512 ceros de maestría, de jugadores que nunca jugaron ese campeón.

### 3 · Qué hipótesis salió mal, y qué hicieron con eso

EZEQUIEL

**H1: estábamos convencidos de que los tanques alargaban la partida, y dio −0,008, con el signo al revés. La escribimos refutada tal como salió.**

Y no descartamos `num_tanks` por eso: sigue en la tabla de candidatas. También salió mal H4, la del elo, y H2 arrancó en amarillo cuando esperábamos verde.

### 4 · Qué columna descartaron por fuga, y cuándo se completa en la realidad

COCHA

**Ninguna, y es una respuesta con contenido: el esquema tiene sólo condiciones iniciales. No hay kills, oro, torres ni resultado. Pero declaramos dos reparos.**

**Uno:** elo, winrate y maestría se leen días después de la partida, así que ya incluyen esa partida. No filtran la duración, pero no son el valor al arrancar. El winrate es el peor, porque cuenta la victoria o derrota entera, y ya sale por H6. **Dos:** el carril sale de `teamPosition`, que Riot completa al cerrar la partida. En producción habría que tomarlo de la selección de campeones. Está en Sección 9 · «El chequeo de fuga…».

### 5 · Qué quedó inconcluso y qué haría falta

FACUNDO

**Cuatro cosas, en Sección 9 · «Qué quedó inconcluso…».**

**1.** Si la señal está en combinaciones de columnas: hace falta un modelo con interacciones, de la Unidad 3. **2.** Las 26 partidas con 9 o 10 jugadores imputados: hace falta el bronce de la corrida grande. **3.** Si los valores previos a la partida cambian algo: hay que leer elo y maestría antes del arranque y volver a recolectar. **4.** La composición de campeones: en el cuartil de partidas más largas Brand y Teemo aparecen 1,35 veces lo esperado y Kalista 0,61; quedó como candidata a novena ficha.

SECCIÓN 7

## Banco de preguntas dirigidas

El dueño es quien contesta primero si la pregunta va al grupo. Si va dirigida a otro, contesta ése: por eso los cuatro leen todo.

«¿Por qué ocho fichas, si la consigna pide cuatro?» COCHA

**Porque cada decisión de columna necesitaba su número. Pero están ordenadas: las cuatro primeras, H1 a H4, cumplen solas la consigna —de las dos preguntas, y dos refutadas— y son las cuatro que proponemos.**

Las cuatro restantes sacan columnas duplicadas o casi constantes. Sin ellas, esas columnas habrían quedado adentro sin nada que lo justifique.

«Las cuatro verdes no miden contra el objetivo. ¿No es trampa?» COCHA

**No: la consigna pide también hipótesis que deciden sobre una columna del modelo, y una columna que duplica a otra sale aunque las dos sean inútiles para predecir.**

Trampa sería presentar el 0,711 entre elo y winrate como señal contra la duración, y no lo hacemos. El verde no es una feature buena: es una redundancia. Esas cuatro sacan 28 columnas.

«¿Por qué una sola ficha usó un movimiento?» TOTO

**Porque el semáforo sólo habilita movimientos en amarillo, y de los ocho números sólo el de H2 cayó ahí.**

Verde y rojo cierran. Insistir sobre un rojo, partiendo el dataset hasta que algo dé, es cazar resultados.

«En H7, $\eta^2$ da verde y Pearson amarillo. ¿Eligieron la que convenía?» COCHA

**No: la forma de la afirmación fija la medida antes de medir. «Difiere entre grupos» es una comparación, y eso es $\eta^2$.**

Los dos números están a la vista en la ficha. Y el control descarta que $\eta^2$ se infle por tener once grupos: la misma categoría contra la duración da 0,001.

«H5 y H7 salieron de mirar la matriz. ¿No rompe la regla del orden?» EZEQUIEL

**No: la regla prohíbe usar el resultado que estás por calcular, no lo que la exploración ya mostró. La fase 6 de la teórica dice que el EDA tiene que generar preguntas nuevas.**

Las dos lo declaran en su primera casilla, y lo que agregan es la decisión: medir a nivel de partida y resolver qué columna sale.

«Si nada correlaciona con la duración, ¿el proyecto no sirve?» FACUNDO

**Correlación mide una columna a la vez y de forma monótona. Lo que sabemos es que no hay una feature obvia; si hay señal, está en combinaciones, y eso lo decide el modelo.**

Y ahora hay un rival claro: predecir siempre la media, 1.748 segundos. Si el modelo no le gana con claridad, la respuesta es negativa, y eso también es un resultado.

«¿Por qué el elo entra a la Entrega 3 si H4 se refutó?» FACUNDO

**Se refutó que el elo *explique* la duración, no la columna. Sigue siendo la más asociada al objetivo de las 137, −0,161.**

«¿Qué entra al modelo, entonces?» COCHA

**De las 137 columnas, 82 no entran como feature y 54 sí, más el objetivo. Está en Sección 9 · «La tabla de columnas candidatas», y la celda siguiente verifica que cubre las 137.**

Salen 30 por las fichas (H6: 10 · H2: 12 · H7: 4 · H5: 2 · H8: 2), los 10 `champ_name` por duplicar a `champ_id`, los 40 códigos `sum1`, `sum2`, `rune_primary` y `rune_sub`, y `match_id` y `roles_inferidos`. Entran agregadas: elo por partida, maestría en logaritmo por jugador, `champ_id` como categórica, y los agregados de equipo como 12 sumas.

«¿Cómo saben que el escalón de 900 s no es un bug?» EZEQUIEL

**Porque cae en el segundo exacto en que el juego habilita la rendición. Un artefacto del pipeline no tendría por qué caer justo ahí.**

«¿Por qué no sacaron los outliers de duración?» EZEQUIEL

**Porque son el fenómeno: una partida de 66 minutos es real, y una de 5 es una rendición temprana. Sacarlas recortaría justo lo que el modelo tiene que explicar.**

137 duran menos de 10 minutos y 289 más de 45. El único recorte legítimo ya está hecho: los remakes de menos de 300 s.

«Trece millones de puntos de maestría, ¿no es un bug?» TOTO

**Lo verificamos contra el bronce, jugador por jugador: 200 celdas comparadas contra el `championPoints` crudo, 200 coincidencias exactas. Es un *one-trick* real.**

Respuesta oral: esa verificación no está en el notebook. Está en la documentación integral, sección 5.6. Se hizo sobre las 20 partidas del bronce de una máquina, no sobre las 19.145, pero valida la lógica de la transformación.

«¿Por qué no agregaron una bandera es_unranked?» TOTO

**Porque no cambia la duración: las 615 partidas con jugadores imputados duran una mediana de 1.788 segundos contra 1.750 del resto, separación 0,067, rojo.**

Respuesta oral: esa medida se quitó del notebook al simplificarlo, y se recalculó el 22/9 sobre el mismo CSV. El pipeline ya calcula `es_unranked` en `include/lol/riot.py` pero no lo escribe al CSV. La conclusión vale para este objetivo.

«¿El dataset tiene dimensión temporal?» FACUNDO

**No: ninguna columna es una fecha, y la fase temporal no aplica. Decirlo es parte del análisis.**

Además todas las partidas son de parches 16.x y los agregados usan un único snapshot de Data Dragon, el 16.17.1. Es una ventana de recolección de unos días de septiembre, y las conclusiones valen para esa ventana. Sección 5 del notebook.

LO QUE NO ESTÁ EN NINGÚN LADO, Y NO SE INVENTA

Si el docente pregunta algo que no está en el notebook, en este guión ni en la documentación integral, la respuesta es «eso no lo medimos», y si se puede, qué haría falta para medirlo. Es exactamente lo que la consigna pide para lo inconcluso.

---

Guión de la Entrega 2 · Grupo 5K09-02 · preparado el 22/9/2026 sobre el notebook reordenado de esa fecha. Los números salen de las salidas guardadas del notebook o se recalcularon sobre `notebooks/entrega-2/datos/lol_2026-09-06.csv`. Documento de apoyo: `docs/documentacion-proyecto.pdf`, parte VIII.