Análisis Exploratorio de los Datos

Ciencia de Datos
Clase 3

Objetivos del EDA

Bloque 1

"El análisis exploratorio de datos (EDA) es un enfoque para el análisis de datos que emplea diversas técnicas para:

- **Observar los datos y ver qué parecen indicar,**
- **Descubrir estructuras subyacentes,**
- **Aislar variables importantes,**
- **Detectar valores atípicos y otras anomalías, y**
- **Sugerir modelos adecuados de la estadística convencional."**

"*Encyclopedia of Database Systems*"

J. T. Behrens

Si bien el término "Análisis Exploratorio de Datos" se popularizó gracias a John Tukey en la década de 1970, la práctica de explorar datos para entenderlos **es tan antigua como la estadística misma**.

El EDA propone un enfoque flexible y abierto: en lugar de aplicar modelos predefinidos desde el inicio, se comienza **explorando para descubrir patrones, anomalías y relaciones** que puedan orientar el análisis posterior.

Esta fase inicial es clave para **evitar conclusiones apresuradas**, ya que permite detectar:

- **Problemas de calidad** en los datos,
- **Generar hipótesis fundadas** y
- **Seleccionar las técnicas** más adecuadas para responder a las preguntas del estudio.

Objetivos del Análisis Exploratorio de Datos

Podemos resumir sus principales objetivos en los siguientes puntos:

- Comprender la naturaleza del dataset
- Identificar patrones y relaciones iniciales
- Detectar problemas y anomalías
- Guiar el modelado posterior

Naturaleza del Dataset

Antes de cualquier análisis avanzado, es fundamental saber y **entender** qué datos tenemos

- **Cuántas** filas y columnas hay.
- Qué **representa cada columna** y qué unidades o categorías usa.
- **Tipos de variables**: numéricas, categóricas, fechas, texto.
- Contexto de **obtención de los datos**: cómo y cuándo fueron recolectados.



Tipos de Variable

Numéricas

- Continuas/Discretas.
- Calcular medidas de tendencia central y Dispersión.
- Analizar su distribución.
- Detectar valores extremos y decidir si mantenerlos o tratarlos.

Categóricas

- Nominales/Ordinales.
- Calcular frecuencias absolutas y relativas.
- Representar con gráficos de barras o tablas de frecuencia.

Temporales

- Formato válido de fecha/hora.
- Extraer componentes relevantes (año, mes, día, hora, día de la semana).
- Analizar tendencias, estacionalidad y patrones cíclicos.
- Identificar huecos o irregularidades en el registro.

Texto Libre

- Analizar longitud y estructura.
- Buscar patrones o palabras clave.
- Estandarizar formato.

Identificar patrones y relaciones

El EDA permite encontrar **tendencias generales** y posibles relaciones:

- **Distribuciones**: ¿la variable es simétrica, sesgada, multimodal?
- **Relación entre variables**: ¿a mayor edad hay mayor ingreso?, ¿los productos más caros se venden menos?
- **Diferencias entre grupos**: por ejemplo, si el promedio de ventas difiere entre regiones.

Este tipo de hallazgos orienta qué preguntas vale la pena investigar en profundidad.



Detectar problemas y anomalías

Los datos rara vez llegan “limpios”. El EDA ayuda a:

- Detectar **valores faltantes** y evaluar su **impacto** (sesgo, calidad de modelos)
- Encontrar **valores extremos** (outliers) que podrían ser errores o casos especiales.
- Identificar **inconsistencias de formato** o codificación (por ejemplo, "Argentina" y "ARG" como valores distintos en una misma columna).
- Reconocer **duplicados**.



Valores faltantes

CASOS:

- Porcentaje de renglones con faltante
- Registros con alto porcentaje de faltantes.
- Correlación (si/no) de faltantes con alguna otra variable? (siempre faltan en local de Mendoza)
- No es random la distribución de faltantes (e.g., los sueldos altos suelen faltar).



IMPACTOS:

- Eliminar filas
  - Sin sesgo: reduce tamaño de muestra.
  - Con sesgo: impacta medias, medianas, correlaciones resultando en posibles **relaciones espurias!**
- Algoritmos intolerantes a faltantes.

ESTRATEGIAS EDAs:

- Mapas de calor de valores faltantes,
- Gráficos de barras con % por variable
- Comparar distribuciones de otras variables: total y la de faltantes.

Valores extremos (outliers)

- **Valores imposibles**: requiere conocimiento del dominio para preguntarse si tal valor podría ocurrir en la práctica.
  - e.g., edad negativa o superior a 150 años (reglas de negocio„ violacion limites fisicos o logicos).
- **Técnicas estadísticas**: (z-score, boxplots, inter-quartile range (IQR))
  - e.g., puntos a mas de 3 sd de la media. **Los identifica**, pero no determina si son o no errores.
- **Comparación con otras variables**: cliente con gasto muy alto, pero también con muchas transacciones.



Guiar el modelado posterior

El EDA **no es un fin en sí mismo**: sirve para tomar mejores decisiones en el modelado.

- Qué variables son **relevantes**?
- Qué **transformaciones** son necesarias (normalización, codificación de categorías, imputación de faltantes).
- Qué **hipótesis** vale la pena probar.

Si en el EDA descubrimos que una variable tiene el 80% de valores faltantes, probablemente no sea útil en el modelo, o requerirá una estrategia especial.



Fases del Análisis Exploratorio de los Datos

Bloque 2

Inspección inicial del dataset

Objetivo: construir un mapa mental del dataset antes de entrar en detalles.

- **Dimensiones**: cuántas filas (observaciones) y columnas (variables).
- **Nombres y significado de variables**: qué mide cada una, y en qué unidades o categorías.
- **Tipos de datos**: identificar si son numéricos, categóricos, fechas o texto libre.
- **Formato y estructura**: por ejemplo, si está en formato CSV, Excel, base de datos, JSON, etc.

```
RangeIndex: 1000 entries, 0 to 999
Data columns (total 15 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   id               1000 non-null   int64
 1   name             1000 non-null   object
 2   height           1000 non-null   int64
 3   weight           1000 non-null   int64
 4   base_experience  1000 non-null   int64
 5   generation       966 non-null    object
 6   is_legendary     1000 non-null   bool
 7   type_1           1000 non-null   object
 8   type_2           503 non-null    object
 9   hp               1000 non-null   int64
 10  attack           1000 non-null   int64
 11  defense          1000 non-null   int64
 12  special-attack   1000 non-null   int64
 13  special-defense  1000 non-null   int64
 14  speed            1000 non-null   int64
dtypes: bool(1), int64(10), object(4)
memory usage: 110.5+ KB
```

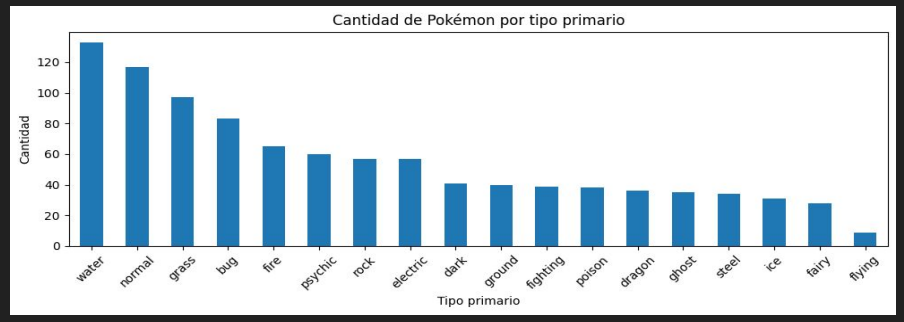
Análisis Univariado

Objetivo: detectar comportamientos atípicos en un análisis aislado de cada variable.

- **Variables numéricas**:
  - **Tendencia central:** mínimo, máximo, media, mediana,
  - **Dispersión:** desviación estándar, percentiles.
  - **Distribución**: histograma, densidad, frecuencias, forma de la curva, asimetría, presencia de picos o huecos.

	id	height	weight	base_experience	hp
count	1000.000000	1000.000000	1000.000000	1000.000000	1000.000000
mean	500.500000	11.988000	646.316000	148.191000	69.677000
std	288.819436	12.461346	1180.512663	76.984018	26.556919
min	1.000000	1.000000	1.000000	36.000000	1.000000
25%	250.750000	5.000000	85.000000	66.000000	50.000000
50%	500.500000	10.000000	280.000000	157.000000	66.000000
75%	750.250000	15.000000	657.750000	182.000000	82.000000
max	1000.000000	200.000000	9999.000000	608.000000	255.000000

- **Variables categóricas**:
  - **Balance de clases**: conteo de frecuencias, proporciones y categorías menos frecuentes.



Caso de Estudio Univariado:
Variable Categórica: INGRESOS MENSUALES

Interpretación:

- Media inflada por valores muy altos.
- Mediana representa mejor al cliente típico.
- Gran dispersión → población heterogénea.
- Posible segmento premium en clientes de >10k USD.

```
- Mínimo: 300
- Máximo: 50,000
- Media: 3,500
- Mediana: 2,200
- Desviación estándar: 5,200
- Asimetría: +4.5 (cola a la derecha)
```

Caso de Estudio Univariado:
Variable Categórica: MÉTODO DE PAGO

Interpretación:

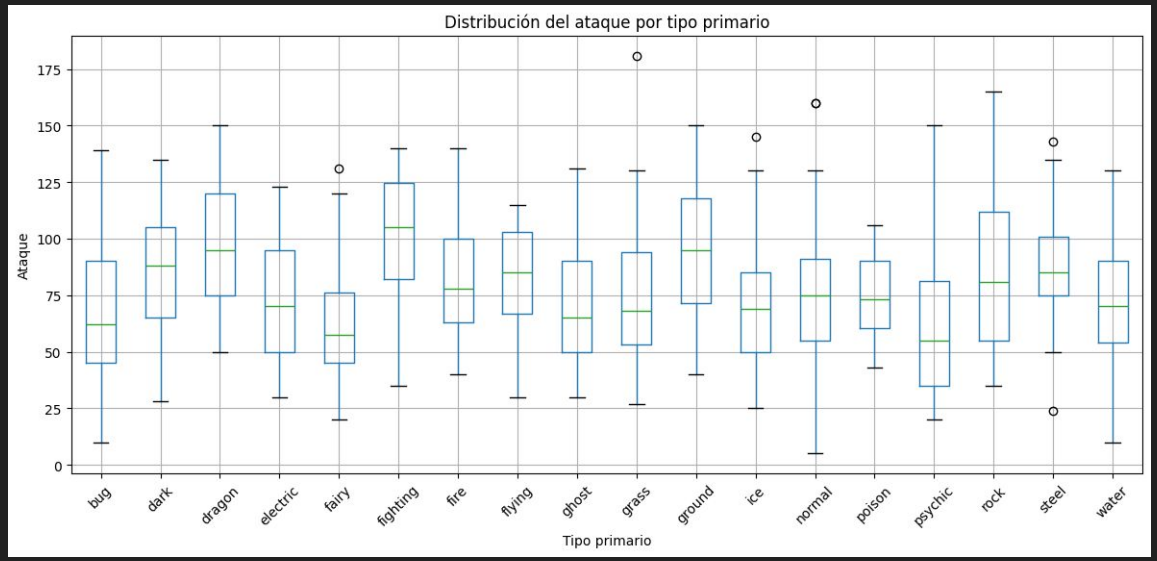
- Dataset muy desbalanceado hacia tarjeta.
- Un modelo sin ajuste siempre predecirá 'tarjeta'.
- Oportunidad de negocio: incentivar transferencias para reducir comisiones.

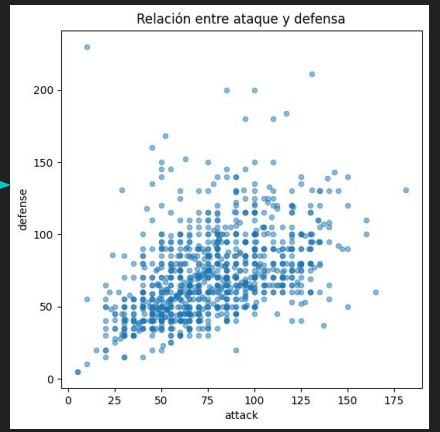
```
- Tarjeta: 85%
- Efectivo: 10%
- Transferencia: 5%
```

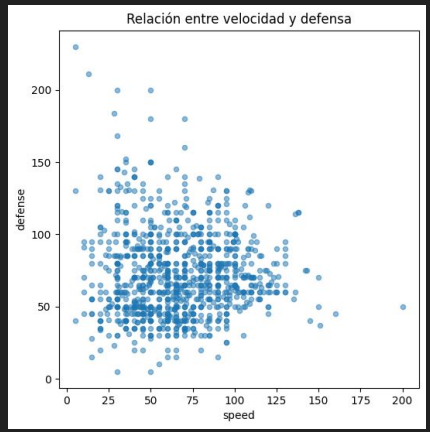
Análisis Bivariado

Objetivo: estudiar relaciones entre dos variables para detectar:

- **Dependencias:** como cambia una variable respecto a otra
- **Agrupamientos naturales:** diferencias entre categorías o segmentos
- **Tendencias o correlaciones**: si hay relación positiva/negativa.





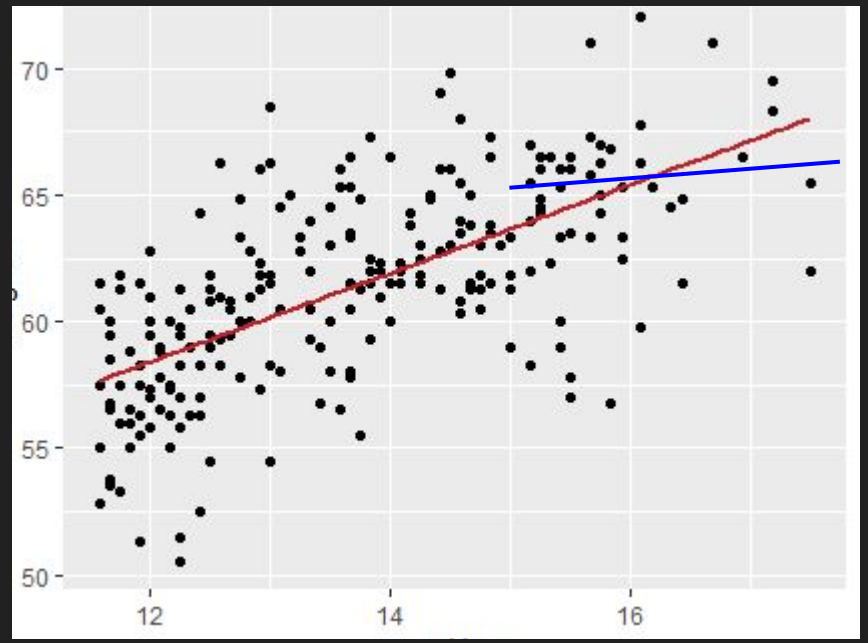


Caso de Estudio Bivariado

Correlación entre dos **variables numéricas**

Dos variables numéricas (correlación)

- Variables: **Edad** vs **Ingreso mensual**.
- **Resultado**: Se observa que **a mayor edad, mayor ingreso hasta cierto punto** (curva ascendente hasta 50 años, luego se estabiliza).
- **Insight de negocio:** segmentar clientes por edad para productos premium (40–55 años son los de mayor poder adquisitivo).



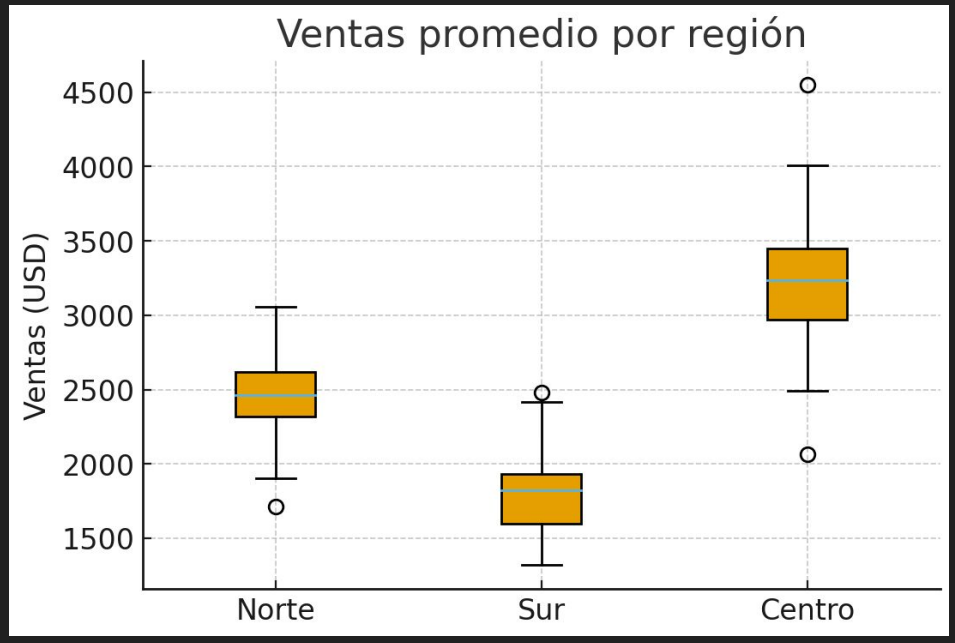
Caso de Estudio Bivariado

Correlación entre variable **numérica y categórica**

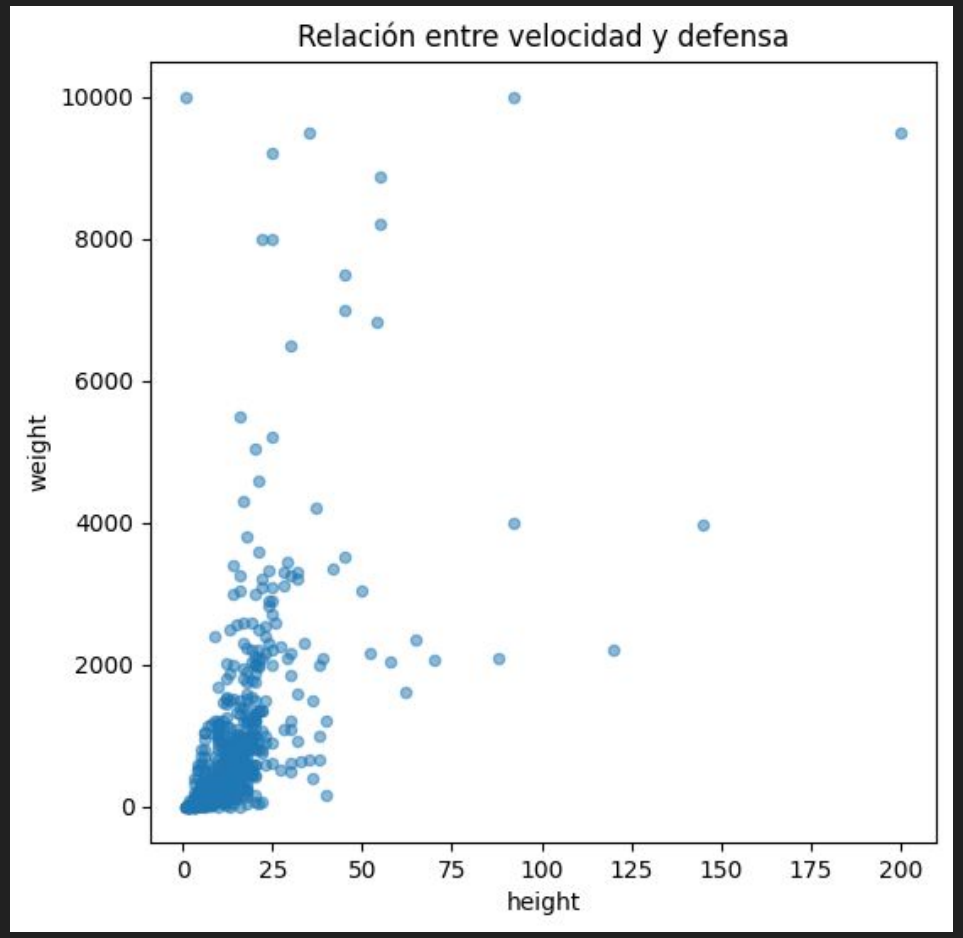
Variables numérica vs categórica (comparación de grupos):

- Variables: **Ventas promedio** vs **Región**.
- **Resultado**:
  - **Región Norte**: promedio = 2500
  - **Región Sur**: promedio = 1800
  - **Región Centro**: promedio = 3200

- **Insight de negocio:** la Región Centro tiene ventas significativamente más altas → conviene reforzar inversión en esa zona.



Análisis de Calidad de Datos



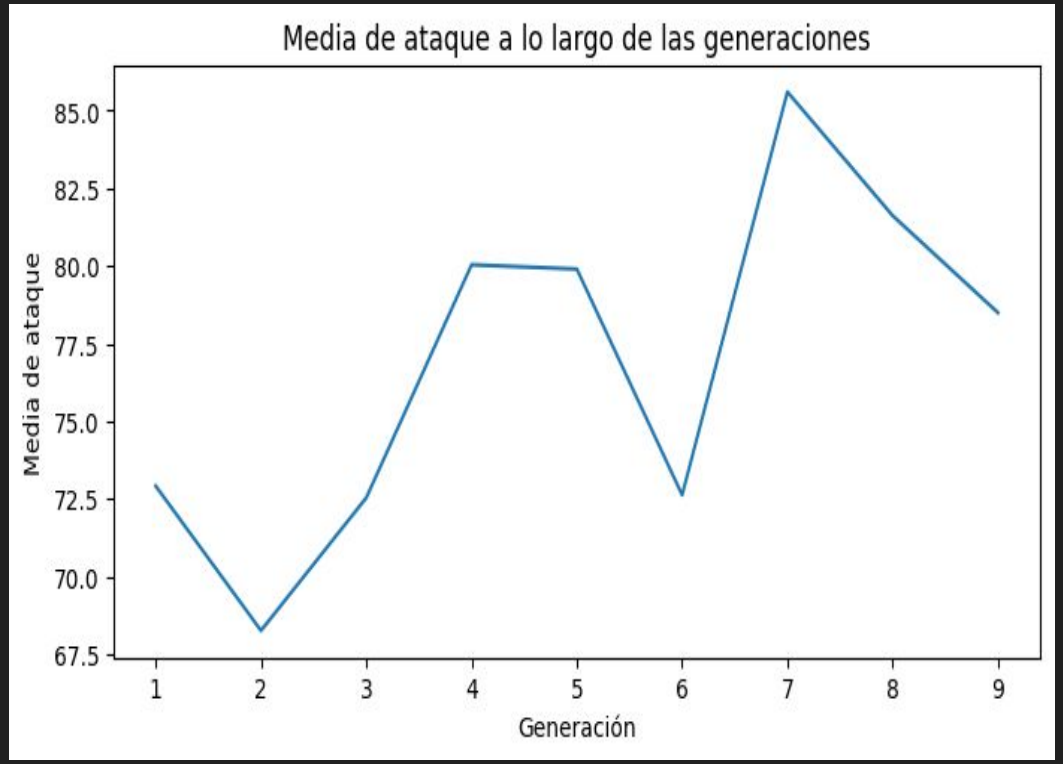
Objetivo: definir estrategias de limpieza y preparación para el modelado.

- **Valores faltantes**: porcentaje, distribución y posibles causas.
- **Duplicados**: si hay registros repetidos que no aportan nueva información.
- **Inconsistencias**: errores de codificación, cambios en nomenclatura, formatos mezclados.
- **Valores extremos**: decidir si son errores o casos válidos que requieren tratamiento especial.

Análisis temporal o secuencial

Objetivo: detectar patrones dinámicos que no se ven en un análisis estático.

- **Tendencias generales**: aumento o disminución a lo largo del tiempo.
- **Estacionalidad**: patrones repetitivos en periodos definidos (semanales, mensuales, anuales).
- **Ciclos**: fluctuaciones de largo plazo no ligadas a estacionalidad.



Generación de hipótesis

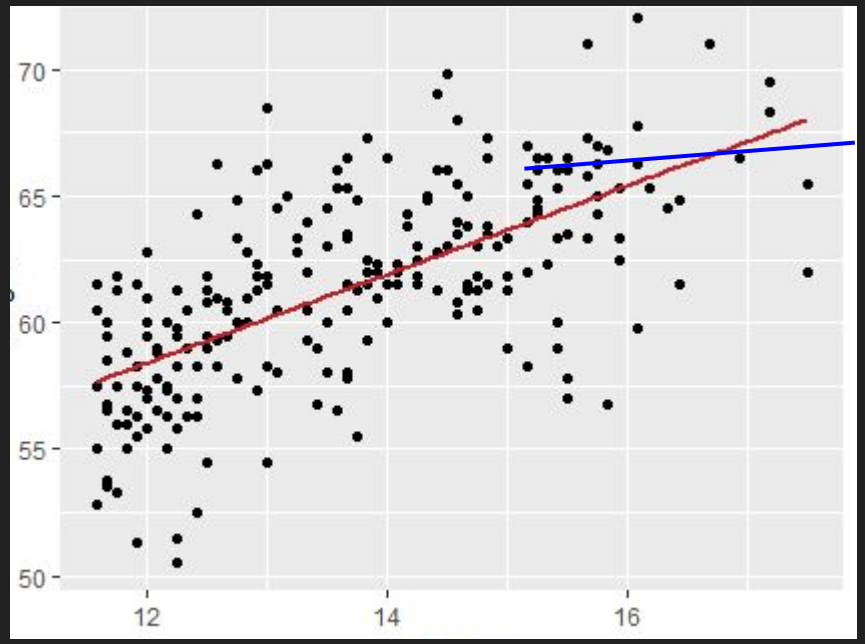
El EDA no solo responde preguntas, sino que ayuda a **formular nuevas**.

- ¿Qué **factores** podrían explicar un patrón detectado?
- ¿Hay **relaciones inesperadas** que valga la pena investigar?
- ¿Qué **supuestos iniciales** se confirman o se contradicen?



Generación de hipótesis
Edad y gasto de producto premium

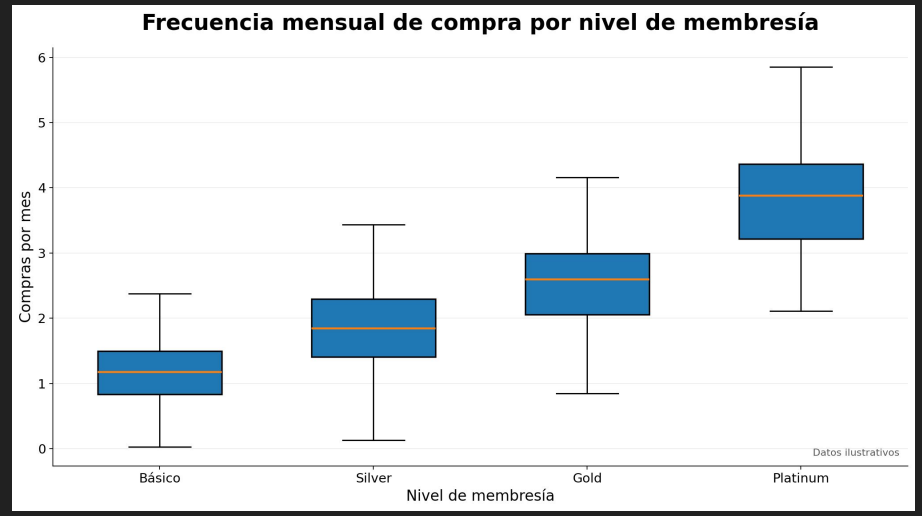
- **EDA inicial:** Scatterplot Edad vs Gasto premium, histograma de gasto por rangos de edad.
- **Observación:** personas entre 35 y 50 años gastan más en productos premium.
- **Hipótesis:** “Clientes de 35 a 50 años son más propensos a comprar productos premium.”
- **Prevalidación:** analizar promedios de gasto por rango de edad; ver distribución de clientes activos.
- **Oportunidad de proyecto:** construir un **modelo de recomendación de productos premium**, usando features de edad, historial de compras y segmentación demográfica. Esto puede optimizar campañas de marketing y upselling.



Generación de hipótesis

Frecuencia de compra y lealtad programa de puntos

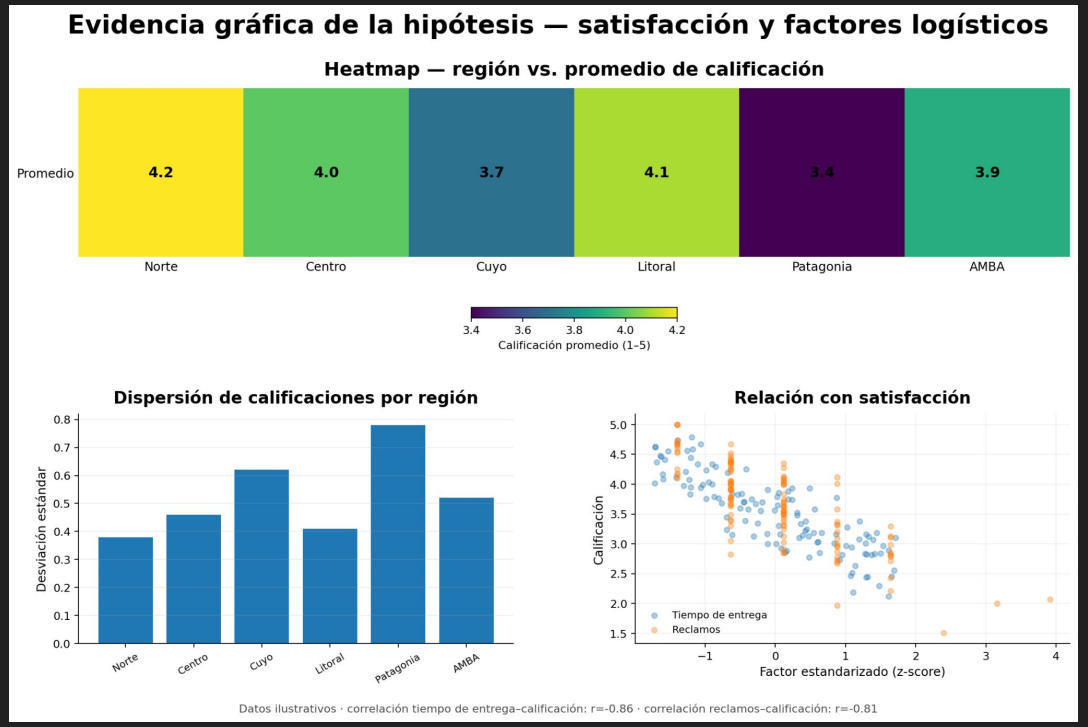
- **EDA inicial:** Boxplot de compras mensuales vs nivel de membresía; tabla de recencia-frecuencia-valor monetario (RFM) por nivel de membresía.
- **Observación:** clientes con niveles más altos compran más seguido y tienen ticket promedio mayor.
- **Hipótesis:** “Un programa de fidelidad más robusto incrementa la frecuencia y el valor de compra de los clientes.”
- **Prevalidación:** calcular correlaciones entre nivel de membresía y frecuencia; ver crecimiento en cohortes.
- **Oportunidad de proyecto:** desarrollar un **modelo de propensión de upgrade de membresía**, que prediga qué clientes pueden pasar al nivel superior si se les incentiva, optimizando ingresos y retención.



Generación de hipótesis

Región geográfica y satisfacción del cliente

- **EDA inicial:** Heatmap Región vs Promedio de calificación; análisis de desviación estándar por región; correlación con tiempos de entrega y reclamos.
- **Observación:** ciertas regiones muestran consistentemente calificaciones bajas o dispersas.
- **Hipótesis:** “La satisfacción del cliente depende de factores logísticos específicos de la región.”
- **Prevalidación:** calcular correlación entre calificación y tiempo de entrega, tasa de reclamos; identificar outliers regionales.
- **Oportunidad de proyecto:** crear un **modelo de predicción de satisfacción**, usando región, tiempos de entrega, tipo de producto y servicio al cliente, para priorizar mejoras operativas y predecir riesgos de churn por región..



Herramientas Conceptuales

Bloque 3

Estadística Descriptiva

Se enfoca en resumir y describir las características más importantes de los datos.

- Principales medidas para variables numéricas
  - Medidas de **tendencia central**: media, mediana, moda.
  - Medidas de **dispersión**: rango, varianza, desviación estándar, rango intercuartílico.
  - Medidas de **forma**: asimetría, curtosis.
- Principales medidas para variables categóricas
  - **Frecuencia absoluta**: número de veces que aparece cada categoría.
  - **Frecuencia relativa**: proporción o porcentaje de cada categoría.
  - **Moda**: categoría más frecuente.

Visualización exploratoria

La visualización permite detectar relaciones, patrones y anomalías que no siempre son evidentes en tablas de números.

- Gráficos típicos para variables numéricas
  - Histograma: distribución de valores y forma de la curva.
  - Boxplot (diagrama de caja): mediana, dispersión y outliers.
  - Gráfico de dispersión (scatter plot): relación entre dos variables numéricas.
- Gráficos típicos para variables categóricas
  - Gráfico de barras: comparación de frecuencias entre categorías.
  - Gráfico circular (pie chart): proporciones (menos recomendado para muchas categorías).