Kit de arranque

Proyecto Integrador · Ciencia de Datos 2026

UTN FRM — INGENIERÍA EN SISTEMAS DE INFORMACIÓN · CLASE 1 · 12/08/2026

Este documento es lo mínimo que necesitás para arrancar hoy. Queda publicado en el campus todo el cuatrimestre: es el mapa del proyecto de punta a punta. El detalle de qué se pide en cada entrega está en el mosaico de cada unidad, y cómo se corrige, en la página **Cómo se evalúa**.

Hoy alcanza con esto.

---

1. Qué es el Proyecto Integrador

Un proyecto de ciencia de datos **de punta a punta**, sobre un problema que elige tu grupo y datos que consigue tu grupo. Empieza hoy y termina el 18 de noviembre.

Vas a recorrer el ciclo completo: conseguir los datos y automatizar su descarga, explorarlos, modelarlos, visualizarlos y comunicar lo que encontraste en una aplicación funcionando.

Es el eje de la materia, no un anexo. Tres datos para dimensionarlo:

- Vale el **50 % de la nota final** — el doble que los cuatro trabajos prácticos juntos, el doble que los dos parciales.
- Ocupa **cuatro clases completas** del cuatrimestre, dedicadas exclusivamente a las entregas.
- Cada TP práctico de la materia está diseñado para prepararte para la entrega del integrador que viene después.

Se aprueba con el 60 %. Hay una instancia de recuperación al final del cursado.

---

2. Qué tenés que resolver hoy

Dos cosas, y las dos salen cerradas de esta clase:

	Qué	Cómo queda registrado
1	**Tu grupo**, de 5 a 6 integrantes	Formulario de la cátedra, antes de terminar la clase
2	**Tu pregunta y tu fuente de datos**, validadas por el docente	Mismo formulario

Que salgan cerradas hoy no es un formalismo. Todo lo que viene después se apoya en esta decisión: el pipeline que vas a construir, el análisis que vas a hacer sobre él, el modelo que vas a entrenar y la aplicación que vas a mostrar en noviembre.

Una fuente floja no da la cara enseguida — aguanta la primera entrega y recién se rompe en septiembre u octubre, cuando hay que modelar. Para ese momento, cambiar de fuente significa rehacer todo lo anterior con la mitad del cuatrimestre encima. Los veinte minutos que le dediques hoy a revisar los criterios valen más que cualquier otra cosa que hagas esta clase.

---

3. Primero la pregunta, después la fuente

En ese orden. No al revés.

1. ¿Qué querés investigar? Una pregunta acotada, sobre una unidad concreta — un jugador, una transacción, un país-año, un tweet, un paciente.

2. ¿Qué fuente responde esa pregunta?

Elegir el dataset primero e inventar la pregunta después lleva a proyectos mecánicos, que se hacen cuesta arriba a partir de septiembre. Vas a convivir cuatro meses con esta decisión: que el tema te interese de verdad importa más de lo que parece ahora.

De dónde pueden salir las preguntas: predicción de comportamientos (abandono de clientes, deserción, demanda), análisis de opiniones o textos, segmentación de usuarios o productos, detección de anomalías, patrones espaciales o temporales, análisis de redes. También sirve —y suele funcionar mejor— algo del entorno local, de la facultad, de un trabajo o de un interés personal.

---

4. Los 7 criterios de una buena fuente

Se desarrollan en el bloque 2 de hoy, con ejemplos. Acá va el resumen para tenerlo a mano mientras buscás.

Eliminatorios — sin esto no hay proyecto

#	Criterio	Qué significa
1	**Datos tidy**	Cada fila es una observación, cada columna una variable
2	**Unidad alineada con tu pregunta**	La unidad de cada fila coincide con aquello sobre lo que querés concluir
3	**Algo modelable**	Hay una variable a predecir, **o** grupos naturales que sospechás encontrar
4	**Descargable de forma automatizada**	URL, API o página scrapeable. Sin intervención humana

Si tu fuente falla uno solo de estos cuatro, no insistas: buscá otra o ajustá tu pregunta.

Facilitadores — no rompen el proyecto, pero lo complican

#	Criterio	Objetivo	Salida si no lo cumplís
5	**Volumen suficiente**	> 1.000 filas; ideal > 10.000	Combinar con otra fuente, o acotar el alcance
6	**Varias columnas informativas**	≥ 5 útiles, mezclando numéricas, categóricas y fechas	Derivar variables nuevas, o cruzar con otra fuente
7	**Documentación entendible**	Saber qué significa cada columna y sus unidades	Reconstruirla leyendo los datos. Cuesta tiempo

Si sobre alguno de los siete no podés responder con certeza, todavía no tenés tu fuente.

---

5. Errores de años anteriores que no queremos repetir

- **Datos ya agregados.** Promedios por provincia, totales por año. Perdiste la observación individual y con ella la posibilidad de modelar.
- **Sin variable objetivo ni estructura latente.** Un listado de museos con su dirección es información, no un problema de ciencia de datos. En la unidad 3 el proyecto se rompe.
- **Muy pocas filas.** Con 200 registros los modelos no aprenden y los gráficos cuentan anécdotas.
- **Una sola columna útil.** Sin features no hay modelo, y sin dimensiones no hay visualizaciones que cruzar.
- **Bajable solo a mano.** Un PDF con una tabla adentro, un sitio con captcha, una base privada. La unidad 1 pide un pipeline automatizado.
- **Fuente elegida por descarte, sin interés real.** Es el que más caro sale: son cuatro meses.

---

6. Cómo se ve el cuatrimestre completo

Cuatro entregas parciales, una por unidad, más la exposición final.

Entrega	Fecha	Qué se presenta
Definición	12/08 (hoy)	Grupo, pregunta y fuente de datos
1 · Ingeniería de datos	02/09	Pipeline automatizado que produce tu dataset
2 · Análisis exploratorio	16/09	Exploración, hipótesis y hallazgos sobre tus datos
3 · Modelado	14/10	Objetivo predictivo, modelos comparados y métricas
4 · Visualización e integración	04/11	Visualizaciones y aplicación funcionando
Exposición final	18/11	Presentación del proyecto completo y demo en vivo
Recuperación	25/11	*Instancia para los grupos que la necesiten*

Cómo son las entregas parciales. Cada grupo se reúne **en privado con el docente**: exponen el avance, el docente pregunta y devuelve en el momento. No hay audiencia de otros grupos. La **exposición final** sí es pública, frente al curso.

La evaluación es individual. Aunque el trabajo sea grupal, en cada entrega las preguntas van dirigidas a integrantes puntuales. Con grupos de 5 o 6 personas esto importa: repartir el trabajo está bien, desentenderse de las partes ajenas no.

---

7. Los TPs prácticos son tu entrenamiento

Durante el cuatrimestre vas a hacer cuatro trabajos prácticos, uno por unidad, **todos sobre un mismo dataset: FIFA**, que la cátedra provee.

No son una materia paralela. Cada TP te enseña la técnica con un caso controlado, y la entrega del integrador que viene después te pide aplicar esa misma técnica a **tu** dataset, que va a ser más sucio, más ambiguo y más difícil.

Unidad	En el TP practicás sobre FIFA	En el Integrador lo aplicás a tu proyecto
1 · Ingeniería de datos	Armar un pipeline que scrapee sofifa.com	Tu pipeline, sobre tu fuente → **Entrega 1**
2 · Análisis exploratorio	Explorar el dataset de jugadores	Tu exploración → **Entrega 2**
3 · Machine Learning	Predecir la posición de un jugador	Tu problema predictivo → **Entrega 3**
4 · Visualización	Visualizar y comunicar los hallazgos	Tus visualizaciones y tu app → **Entrega 4**

La consecuencia práctica: el TP se resuelve en casa y se entrega por campus, pero conviene hacerlo *antes* de encarar la entrega del integrador correspondiente. El orden importa.

---

8. El error de gestión más común

Trabajar el integrador la semana previa a cada entrega.

Las cuatro entregas están separadas por tres o cuatro semanas, y esa distancia genera la ilusión de que hay tiempo de sobra. No lo hay: cada entrega se apoya en la anterior, y llegar con lo mínimo a la Entrega 1 significa arrastrar un pipeline frágil hasta noviembre.

El proyecto se trabaja **en paralelo a la cursada, todas las semanas**. Los espacios de consulta en clase están para eso.

---

9. Antes de irte hoy

- ☐ Grupo armado, de 5 a 6 integrantes
- ☐ Pregunta escrita en una frase
- ☐ Fuente identificada, con su URL
- ☐ Los 7 criterios revisados sobre esa fuente
- ☐ Fuente validada con el docente
- ☐ Formulario completado

Ciencia de Datos · UTN FRM · Ciclo lectivo 2026